

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
PROGRAMŲ SISTEMŲ STUDIJŲ PROGRAMA

Hibridinio genetinio paieškos algoritmo transporto maršrutų optimizavimo uždaviniams spręsti lygiagretinimas

**Parallelization of Hybrid Genetic Search Algorithm for
Solving Vehicle Routing Problem**

Kursinis darbas

Atliko: 4 kurso 1 grupės studentas

Domantas Keturakis

Darbo vadovas: Doc., Dr. Algirdas Lančinskas

Vilnius – 2025

Turiny

Terminai	3
Santrumpos	3
Įvadas	3
HGS algoritmo veikimas	6
Literatūros analizė	7
Lygiagretinimas	9
Metodika	9
Rezultatai	9
Išvados	10
Šaltiniai	11

Terminai

- Populiacija – Rinkinys invididų.
- Individas – Užduoties sprendimas t.y. rinkinys maršrutų.

Santrumpos

- VRP – Martšrutų optimizavimo uždavinys (*angl. Vehicle Routing Problem*).
- CVRP – *angl. Capacitated Vehicle Routing Problem*. Kiekviena transporto priemonė turi maksimalią siuntų talpą.
- VRPTW – *angl. VRP with Time Windows*.
- GVRP – *angl. Generalized VRP*. Taškai grupuojami į klusterius. Tik vienas taškas iš viso klusterio turi būti aplankytas.
- CluVRP – *angl. Clustered VRP*. Taškai grupuojami į klusterius. Visi taškai klusteryje turi būti aplankyti prieš važiuojant į kitą klusterį.
- SoftCluVRP – *angl. Clustered VRP*. Taškai grupuojami į klusterius. CluVRP variantas, kuriame į klusterį leidžiama aplankyti kelis kartus.
- MDVRP – *angl. Multidepot VRP*.
- PVRP – *angl. Periodic VRP*. Pridedama laiko dimescija, t.y. išmetama presumpcija, kad visi taškai turi būti vienu kartu, sprendimas susidaro iš kelių maršrutų rinkinių atitinkačius dienas, kuriomis bus aplankomi taškai.
- MDPVRP – *angl. Multidepot Periodic VRP*. MDVRP ir PVRP kombinacija.
- CVRPPD – *angl. CVRP Pickup and Delivery*. CVRP ir VRPPD kombinacija.

Išvadas

VRP – Transporto maršrutų optimizavimo uždavinys (*angl. Vehicle Routing Problem*) yra uždavinys, kurio tikslas yra surasti kuo optimaliausią maršrutų rinkinį. **TODO: Čia dar reikia pasidomėti iš ko tiksliai susideda COST funkcija.** Optimaliai parinkti maršrutai gali lemti kiek taškų įmanoma aplankyti per nustatytą laiką, sumažinti transporto kaštus. Pirmą kartą ši problema aprašyta [DR59], kur autorius aprašė algoritmą, kuris suranda optimalius maršrutus tarp kuro depo ir degalinių. Tai yra modernios logistikos optimizavimo uždavinys – optimaliai parinkti maršrutai gali lemti mažesnius kainos ir pristatymo laiko kaštus.

Kur keliaujančio pardavėjo uždavinyje pagrindinė užduotis yra surasti optimaliausią kelią vienam keliautojui – pardavėjui, VRP sprendimai susidaro iš kelių keliautojų – literatūroje dažnai tiesiogiai vadinama transporto priemonėmis.

Nors egzistuoja įrankiai, kurie pasiteklia tikslūs metodai (pavyzdžiui „Google or-tools“ [PF25]), kadangi šis uždavinys priklauso **NP-Hard** sudėtingumo klasei, visgi dominuoja heuristikomis ir metaheuristikomis grįsti algoritmai **[CITATION NEEDED]**, nes šie beveik optimalius sprendimus suranda per greitesnį laiko tarpą sunaudodami mažiau resursų. Tikslūs metodai su ypač dideliais kiekiais duomenų tampa nepraktiški **[CITATION NEEDED]**. Metaheuristiciniai algoritmai išsiskiria šioje uždavinių klasėje kaip efektyviausi, pasižymintys žemu algoritmo vykdymo laiku ir aukšta uždavinių rezultatų kokybe.

Praktikoje taikomos VRP variacijos (CVRP, VRPTW, MDPVRP, PVRP ir kt.) įveda papildomus apribojimus maršrutų ilgiui, transporto priemonių panaudojimo laikui ir talpai, ar prideda papildomas sąlygas:

- naudojamos transporto priemonės turi limituotą talpą (CVRP).
- visi taškai turi gali būti aplankyti tik specifinėmis darbo valandomis (VRPTW)
- keli depai iš kurių galima pradėti maršrutą (MDVRP),
- maršrutai planuojami per kelias dienas, t.y. vieni taškai gali būti aplankyti vieną dieną, o kiti kitą. (Periodic VRP).
- kt.

Šis darbas atsižvelgia tik į CVRP uždavinį.

Šiai problemai egzistuoja heuristiniai ir metaheuristiniai (Aukštesnio lygio strategija/karkasas, kuris diriguoja, kurias heuristikas pritaikyti, kad efektyviau atrasti sprendimus) algoritmai. Keli dominuojantys pavyzdžiai [Ada+24]

- „Adaptive Large Neighborhood Search“ ir „Hybrid Adaptive Large Neighborhood Search“
- „Hybrid Genetic Search (HGS)“
- „Simulated Annealing Algorithm (SAA)“
- „Ant colony optimization (ACO)“

Hibridinis genetinis paieškos ((*angl. Hybrid Genetic Search – HGS*)) – yra vienas iš efektyviausių genetinių metaheuristinių algoritmų [Pet+23]. Šis algoritmas ir vėlesnės pagerintos versijos išlieka etalonas daugeliui VRP variantų, „DIMACS“ konkurse [DIM22] parodęs geriausius rezultatus VRPTW uždavinyje [Koo+22], ir kurio modifikuotas variantas [Jia+22] pasirodė geriausiai CVRP uždavinyje. Šis algoritmas yra pritaikytas CVRP, VRPTW, GVRP [Lat25a], CluVRP, SoftCluVRP [Lat25b].

Šio **darbo tikslas** – išlygiagretinti hibridinio genetinio paieškos algoritmą, skirtą transporto maršrutų optimizavimo uždaviniams spręsti, siekiant sumažinti vykdymo laiką neprarandant ar net pagerinant sprendimų kokybę.

Uždaviniai:

1. Išsirinkti duomenų rinkinį pagal, kurį galima būtų testuoti/analizuoti sprendimus, pvz.:
 - tikriausiai CVRPLIB repository (repository of BKSs - Best Known Solutions) (<https://vrp.galgos.inf.puc-rio.br/index.php/en/>)
 - Solomon
 - Neural Combinatorial Optimization for Real-World Routing (2025)
 - Test-data generation and integration for long-distance e-vehicle routing (2023)
 - "New benchmark instances for the Capacitated Vehicle Routing Problem" [Uch+17] (2017)
 - For the CVRP and VRPTW, the BKS values are obtained
 - ▶ [Jas+24] [3/1337 psl.]

from the CVRPLIB repository (<http://vrp.galgos.inf.puc-rio.br/>) as of April 30, 2025. For the CVRP, we use results from HGS-2012 [38] and HGS-CVRP [14]. For the VRPTW, with the objective of minimizing the total travel distance, we reference results from the DIMACS competition, including both the official DIMACS reference results and the champion team's algorithm, HGS-DIMACS [39]. For the VRPSPDTW, we report the best results from the state-of-the-art MA-FIRD method [32].

— Zhenyu Lei, Jin-Kao Hao, Qinghua Wu [LHW25]

2. Išanalizuoti, kaip veikia HGS algoritmas
3. Atrinkti paralelizuojamas dalis, ar dalis, kurias galima pakeisti paralelizuojamomis
4. Palyginti rezultatus su kitais state-of-the-art algoritmais

HGS algoritmo veikimas

Pirma aprašytas "A Hybrid Genetic Algorithm for Multidepot and Periodic Vehicle Routing Problems" [Vid+12] (2012) skirtas spręsti MDPVRP. Patobulintas per daugelį iteracijų: [Vid+14], [Vid+16], [Vid17], [Vid+21], [Vid22] ir pritaikytas CVRP.

- Beyond a simple reimplementa-tion of the original algorithm, HGS- CVRP takes advantage of several lessons learned from the past decade of VRP studies: it relies on simple data structures to avoid move reevaluations and uses the optimal linear-time Split algorithm of Vidal (2016). Moreover, its specialization to the CVRP permits significant methodological simplifications. In particular, it does not rely on the visit-pattern improvement (PI) operator (Vidal et al., 2012) originally designed for VRPs with multiple periods, and uses instead a new neighborhood called Swap*.
— Thibaut Vidal [Vid22]
- In HGS-CVRP, we rely on the efficient linear-time Split algorithm introduced by Vidal (2016) (autoriaus papildymas: [Vid16]) after each crossover operation.
— Thibaut Vidal [Vid22]

Genetiniai algoritmai imituoja evoliucijos procesą. Populiacija yra aibė, kurią sudaro individai (t.y. užduoties sprendimai). Šie algoritmai naudoja įvairius kryžminimo operatorius, kurie iš kelių individų populiacijoje sukuria naują, mutuotą individą ir prideda prie populiacijos. Prastos kokybės ir panašūs individai (sprendimai) vykdimu eigoje yra pašalinami iš populiacijos.

Genetinis hybridinis paieškos algoritmas prie genetinio komponento prideda pagerinimo žingsnį (lokalią paiešką), kuri po kryžminimo žingsnio yra pritaikoma mutuotam individui, kad pagerinti gautą individo kokybę.


Lokalioje paieškoje taikomos *relocate*, *2-opt*, *2-opt**, bei *swap** heuristikos.

Palaikant neįvykdomus (*angl. infeasible*) ir įvykdomus (*angl. feasible*) sprendimus, palaikoma populiacijos įvairovė (*angl. diversity*), kuri leidžia išvengti lokalios minimos (*angl. local minima*) iteruojant per sprendimus.

HGS algoritmo pseudokodas [Vid+12]

- 1: Sugeneruoti pradinę populiaciją
- 2: Kol iteracijų skaičius be sprendimo pagerėjimo $<$ nustatytas skaičius ir kol nepraėjo laiko limitas
- 3: Pasirinkti tėvinius sprendimus (**binary tournament**)
- 4: Atlikti kryžminimą (*angl. crossover*)
- 5: Išmokyti **offspring** (atlikti lokalią paiešką)
- 6: jeigu sprendimas neįmanomas:
pridėti sprendimą prie neįvykdomų aibės bei sutaisyti su tam tikra tikimybe
- 7: jeigu sprendimas įmanomas:
pridėti sprendimą prie įvykdomų aibės
- 8: jeigu pasiekas maksimalus sprendimų skaičius:
pasirinkti geriausius ir labiausiai įvairius sprendimus
- 9: Pakeisti **penalty parameters**
- 10: Jeigu geriausias sprendimas per It_{div} iteracijų nepagerėjo:
diversifikuoti populiaciją
- 11: Gražinti geriausią sprendimą

TODO: pridėti swap*



Pav. 2: HGS veikimas [Vid22]

TODO: Išversti į lietuvių k.???


Literatūros analizė

[LHW25] lygiagretinimui lokaliai paieškos algoritmą išreiškia tenzorių operatoriais, tai leidžia HGS vykdymą perkelti ant GPU. Taip pagreitinamas lokaliai paieškos operatorius.

Tačiau [LHW25] pasiūlytas metodas nėra pritaikomas HGS su swap*. „Dabartinė sprendimų reprezentacija per tensorius neleidžia lengvai įgyvendinti apkarpymo strategijų kaimynysčių sumažinimo technikų, kurie dažnai yra naudojami lokalsios paieškos grįžtais algoritmais.“¹

[SND23] HGS pritaiko CVRPPD, perkelia tėvų pasirinkimo (*angl. selection*), kryžminimo (*angl. crossover*) ir taisymo (*angl. repair*) žingsnius į atskiras gijas. Kiekviena gija papildomai atlieka lokalią paiešką (*2-opt*, *relocate*, *swap*) pasitelkiant GPU, tačiau nepasitelkia *swap** heuristika, kuri pagal [Vid22] padeda surasti aukštesnės kokybės sprendimus.

Priešintai nei dauguma implementacijų [Mun+23] naudoja grafų duomenų struktūras, panaudojami tik *2-opt* ir arčiausio kaimyno heuristikos (*angl. nearest-neighbor*). Šios heuristikos pritaikytos vykdymui GPU aplinkoje naudojant CUDA.




Pav. 3: HGS lygiagretintas [SND23]

[YT21] pasitelkia GPU lygiagretinimui. Kiekvienam maršrutui skiriama atskira GPU gija, kuri vykdo lokalsios paieškos žingsnį naudojant GPU. Šiuo metodu pilnas resursų išnaudojimas priklauso nuo to ar sukurtų maršrutų skaičius sutampa su gijų skaičiumi. Atvejai, kai lokalsios paieškos žingsniai modifikuoja kitų maršrutų sprendimą, gijos įrašo savo sprendimą į atskirą masyvą, kuris vėliau yra redukuojamas į vieną sprendimą, pasirenkant geriausią sprendimą. Analogiškai, vėlesnėme žingsnyje kiekvienam taškui priskiriama gija. Kiekviena gija apskaičiuoja pagerėjimą ar pablogėjimą apsikeistus vietą maršrute su kitu tašku.

[Jam+25] kombinuoja HGS su salų modeliu, aprašytu [Rez+24], kur kiekviena gija, vykdo tą patį HGS algoritmą, pridamas individų migracijos žingsnis, kuris leidžia keistis sprendimais tarp gijų.

¹the current design of the tensor representation of solutions doesn't support easy implementation of pruning strategies and neighborhood reduction techniques that are often used in local search-based routing algorithms.



Pav. 4: HGS su salų modeliu [Jam+25]

Lygiagretinimas

Daugiausiai laiko užima lokalios paieškos žingsnis [Jam+25] **TODO: pridėti savo matavimus**. Todėl siekiant sumažinti viso HGS algoritmo vykdymo laiką šį žingsnį yra labiausiai verta lygiagretinti.

Kiekvienai gijai yra parenkami atliekamas kryžminimas. Tada kiekviena gija atlieka lokalios paieškos žingsnį. Vėliau, kai kiekviena gija atlieka šį žingsnį, individai yra pridedami į visų populiaciją.

TODO: praplėsti ir padaryti diagramą

Metodika

Dėl rezultatų palyginamumo pasirinkta naudoti [Vid22] aprašytus duomenų rinkinius ir metodiką.

We monitor each algorithm's progress up to a time limit of $T_{\max} = n \times 240 / 100$ seconds, where n represents the number of customers. Therefore, the smallest instance with 100 clients is run for 4 minutes, whereas the largest instance containing 1000 clients is run for 40 minutes. During each run, we record the best solution value after 1%, 2%, 5%, 10%, 15%, 20%, 30%, 50%, 75%, and 100% of the time limit to measure the performance of the algorithms at different stages of the search.

Gap apibrėžimas.

$$\text{Gap} = \left(\frac{Z_s - Z_{\text{BKS}}}{Z_{\text{BKS}}} \right) \cdot 100\%$$

Z_s = Algoritmo sprendimo kaina

Z_{BKS} = Geriausio sprendimo kaina

TODO: sprendimo kaina/COST apibrėžimas

Rezultatai

TODO: pateikti rezultatus

Iš rezultatų matyti, kad užduočių kokybė t.y. COST nesumažėjo, tačiau vykdymo laikas sumažėjo X kartų iki Y gijų skaičiaus, daugiau didinant gijų skaičių vykdymo laikas vidutiniškai pakilo X kartų

Išvados

TODO

Šaltiniai

- [DR59] G. B. Dantzig ir J. H. Ramser, „The Truck Dispatching Problem“, *Management Science*, t. 6, nr. 1, p. 80–91, spal. 1959, doi: [10.1287/mnsc.6.1.80](https://doi.org/10.1287/mnsc.6.1.80).
- [PF25] L. Perron ir V. Furnon, „OR-Tools“. [Interaktyvus]. Adresas: <https://developers.google.com/optimization/>
- [Ada+24] T. Adamo, M. Gendreau, G. Ghiani, ir E. Guerriero, „A review of recent advances in time-dependent vehicle routing“, *European Journal of Operational Research*, t. 319, nr. 1, p. 1–15, lapkr. 2024, doi: [10.1016/j.ejor.2024.06.016](https://doi.org/10.1016/j.ejor.2024.06.016).
- [Pet+23] F. Petropoulos ir kt., „Operational Research: methods and applications“, *Journal of the Operational Research Society*, t. 75, nr. 3, p. 423–617, gruodž. 2023, doi: [10.1080/01605682.2023.2253852](https://doi.org/10.1080/01605682.2023.2253852).
- [DIM22] DIMACS, „The 12th DIMACS Implementation Challenge: Vehicle Routing Problems (VRP)“. 2022 m.
- [Koo+22] W. Kool ir kt., „Hybrid genetic search for the vehicle routing problem with time windows: A high-performance implementation“, *12th dimacs implementation challenge workshop*, 2022.
- [Jia+22] S. Jiang, Z. He, W. Lin, F. Ma, ir Z. Lü, „FHCSolver: Fast hybrid CVRP solver“, *12th DIMACS implementation challenge: Vehicle routing problems*, 2022.
- [Lat25] V. Latorre, „A hybrid genetic search based approach for the generalized vehicle routing problem“, *Soft Computing*, t. 29, nr. 3, p. 1553–1566, vas. 2025a, doi: [10.1007/s00500-025-10507-0](https://doi.org/10.1007/s00500-025-10507-0).
- [Lat25] V. Latorre, „An application of a two-level genetic search for the soft-clustered vehicle routing problem“, *Evolutionary Intelligence*, t. 18, nr. 4, liep. 2025b, doi: [10.1007/s12065-025-01063-5](https://doi.org/10.1007/s12065-025-01063-5).
- [Uch+17] E. Uchoa, D. Pecin, A. Pessoa, M. Poggi, T. Vidal, ir A. Subramanian, „New benchmark instances for the Capacitated Vehicle Routing Problem“, *European Journal of Operational Research*, t. 257, nr. 3, p. 845–858, kovo 2017, doi: [10.1016/j.ejor.2016.08.012](https://doi.org/10.1016/j.ejor.2016.08.012).
- [Jas+24] T. Jastrzab ir kt., „Standardized validation of vehicle routing algorithms“, *Applied Intelligence*, t. 54, nr. 2, p. 1335–1364, saus. 2024, doi: [10.1007/s10489-023-05212-0](https://doi.org/10.1007/s10489-023-05212-0).
- [LHW25] Z. Lei, J.-K. Hao, ir Q. Wu, „Speeding up Local Optimization in Vehicle Routing with Tensor-based GPU Acceleration“. [Interaktyvus]. Adresas: <https://arxiv.org/abs/2506.17357>
- [Vid+12] T. Vidal, T. G. Crainic, M. Gendreau, N. Lahrichi, ir W. Rei, „A Hybrid Genetic Algorithm for Multidepot and Periodic Vehicle Routing Problems“, *Operations Research*, t. 60, nr. 3, p. 611–624, birž. 2012, doi: [10.1287/opre.1120.1048](https://doi.org/10.1287/opre.1120.1048).

- [Vid+14] T. Vidal, T. G. Crainic, M. Gendreau, ir C. Prins, „A unified solution framework for multi-attribute vehicle routing problems“, *European Journal of Operational Research*, t. 234, nr. 3, p. 658–673, geg. 2014, doi: [10.1016/j.ejor.2013.09.045](https://doi.org/10.1016/j.ejor.2013.09.045).
- [Vid+16] T. Vidal, N. Maculan, L. S. Ochi, ir P. H. Vaz Penna, „Large Neighborhoods with Implicit Customer Selection for Vehicle Routing Problems with Profits“, *Transportation Science*, t. 50, nr. 2, p. 720–734, geg. 2016, doi: [10.1287/trsc.2015.0584](https://doi.org/10.1287/trsc.2015.0584).
- [Vid17] T. Vidal, „Node, Edge, Arc Routing and Turn Penalties: Multiple Problems—One Neighborhood Extension“, *Operations Research*, t. 65, nr. 4, p. 992–1010, rugpj. 2017, doi: [10.1287/opre.2017.1595](https://doi.org/10.1287/opre.2017.1595).
- [Vid+21] T. Vidal, R. Martinelli, T. A. Pham, ir M. H. Hà, „Arc Routing with Time-Dependent Travel Times and Paths“, *Transportation Science*, t. 55, nr. 3, p. 706–724, geg. 2021, doi: [10.1287/trsc.2020.1035](https://doi.org/10.1287/trsc.2020.1035).
- [Vid22] T. Vidal, „Hybrid genetic search for the CVRP: Open-source implementation and SWAP* neighborhood“, *Computers & Operations Research*, t. 140, p. 105643, bal. 2022, doi: [10.1016/j.cor.2021.105643](https://doi.org/10.1016/j.cor.2021.105643).
- [Vid16] T. Vidal, „Technical note: Split algorithm in $O(n)$ for the capacitated vehicle routing problem“, *Computers & Operations Research*, t. 69, p. 40–47, 2016, doi: <https://doi.org/10.1016/j.cor.2015.11.012>.
- [SND23] T. Stadtler, S. Nita, ir J. Dünnweber, „A parallel hybrid genetic search for the capacitated vrp with pickup and delivery“, Ostbayerische Technische Hochschule Regensburg, 2023.
- [Mun+23] R. P. Muniasamy, S. Singh, R. Nasre, ir N. Narayanaswamy, „Effective Parallelization of the Vehicle Routing Problem“, *Proceedings of the Genetic and Evolutionary Computation Conference, GECCO '23*. ACM, liep. 2023, p. 1036–1044. doi: [10.1145/3583131.3590458](https://doi.org/10.1145/3583131.3590458).
- [YT21] P. Yelmewad ir B. Talawar, „Parallel Version of Local Search Heuristic Algorithm to Solve Capacitated Vehicle Routing Problem“, *Cluster Computing*, t. 24, nr. 4, p. 3671–3692, liep. 2021, doi: [10.1007/s10586-021-03354-9](https://doi.org/10.1007/s10586-021-03354-9).
- [Jam+25] M. Jamshidi, M. Alirezanejad, H. Motameni, ir R. Enayatifar, „A Parallel Hybrid Genetic Search for Solving the Capacitated Vehicle Routing Problem“, *International Journal of Computational Intelligence Systems*, t. 18, nr. 1, lapkr. 2025, doi: [10.1007/s44196-025-01059-0](https://doi.org/10.1007/s44196-025-01059-0).
- [Rez+24] B. Rezaei, F. Gadelha Guimaraes, R. Enayatifar, ir P. C. Haddow, „Exploring dynamic population Island genetic algorithm for solving the capacitated vehicle routing problem“, *Memetic Computing*, t. 16, nr. 2, p. 179–202, birž. 2024, doi: [10.1007/s12293-024-00412-8](https://doi.org/10.1007/s12293-024-00412-8).