

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
PROGRAMŲ SISTEMŲ STUDIJŲ PROGRAMA

**Hibridinio genetinio paieškos algoritmo transporto
maršrutų optimizavimo uždaviniams spręsti
lygiagretinimas**

**Parallelization of Hybrid Genetic Search Algorithm for Solving
Vehicle Routing Problem**

Kursinis darbas

Atliko: 4 kurso 1 grupės studentas
Domantas Keturakis

Darbo vadovas: Doc., Dr. Algirdas Lančinskas

Vilnius – 2025

Turinys

Santrumpos	3
Sąvokų apibrėžimai	3
Įvadas	4
1. Transporto maršrutų optimizavimo uždaviniai	5
1.1. Tikslūs ir apytiksliai metodai	5
1.2. VRP variacijos	5
1.3. CVRP	5
2. HGS algoritmo veikimas	7
3. Literatūros analizė	9
4. HGS-CVRP lygiagretinimas	11
5. Lygiagretintos ir nuoseklios programos palyginimas	13
5.1. Metodika	13
5.2. Rezultatai	14
Rezultatai ir išvados	15
Rezultatai	15
Išvados	15
Priedai	16
1. Priedas. Eksperimento parametrai	16
2. Priedas. Vidutinė spraga pagal vykdymo laiką ir gijų skaičių	16
3. Priedas. Spragos santykis tarp viengijės ir daugiagijės versijų	19
4. Priedas. Vidutinės pasiektos sprendimų kainos ir tarpas galutiniu laiko momentu	21
Šaltiniai	25

Santrumpos

Sąvokų apibrėžimai

- Populiacija – Rinkinys individų.
- Individas – Užduoties sprendinys t.y. rinkinys maršrutų.
- HGS – Hibridinis genetinis paieškos algoritmas (*angl. Hybrid Genetic Search*).
- VRP – Transporto maršrutų optimizavimo uždavinys (*angl. Vehicle Routing Problem*).
- CVRP – *angl. Capacitated Vehicle Routing Problem*. Kiekviena transporto priemonė turi maksimalią siuntų talpą.
- VRPTW – *angl. VRP with Time Windows*.
- GVRP – *angl. Generalized VRP*. Klientai grupuojami į klusterius. Tik vienas klientas iš viso klusterio turi būti aplankytas.
- CluVRP – *angl. Clustered VRP*. Klientai grupuojami į klusterius. Visi klientai klusteryje turi būti aplankyti prieš važiuojant į kitą klusterį.
- SoftCluVRP – *angl. Clustered VRP*. Klientai grupuojami į klusterius. CluVRP variantas, kuriame į klusterį leidžiama aplankyti kelis kartus.
- MDVRP – *angl. Multidepot VRP*.
- PVRP – *angl. Periodic VRP*. Pridedama laiko dimensija, sprendinys susidaro iš kelių maršrutų rinkinių atitinkančius dienas, kuriomis bus aplankomi klientai.
- MDPVRP – *angl. Multidepot Periodic VRP*. MDVRP ir PVRP kombinacija.
- CVRPPD – *angl. CVRP Pickup and Delivery*. CVRP ir VRPPD kombinacija.
- BKS – Geriausias žinomas sprendinys (*angl. Best Known Solution*).
- GPU – Grafikos procesorius (*angl. Graphics Processing Unit*).
- Įvykdomas sprendinys – Sprendinys, tenkinantis visus uždavinio apribojimus.

Įvadas

VRP – Transporto maršrutų optimizavimo uždavinys (*angl. Vehicle Routing Problem*) yra uždavinys, kurio tikslas yra surasti kuo optimaliausią maršrutų rinkinį Lygt. 2. Optimaliai parinkti maršrutai gali lemti kiek klientų įmanoma aplankyti per nustatytą laiką, sumažinti transporto kaštus. Pirmą kartą ši problema aprašyta [DR59], kur autorius aprašė algoritmą, kuris suranda optimalius maršrutus tarp kuro depo ir degalinių. Tai yra modernios logistikos optimizavimo uždavinys – optimaliai parinkti maršrutai gali lemti mažesnius kainos ir pristatymo laiko kaštus.

Kur keliaujančio pardavėjo uždavinyje pagrindinė užduotis yra surasti optimaliausią kelią vienam keliautojui – pardavėjui, VRP sprendiniai susidaro iš kelių keliautojų – literatūroje dažnai tiesiogiai vadinama transporto priemonėmis.

Hibridinis genetinės paieškos algoritmas (*angl. Hybrid Genetic Search – HGS*) – yra vienas iš efektyviausių genetinių metaheuristinių algoritmų [Pet+23]. Šis algoritmas ir vėlesnės pagerintos versijos išlieka etalonas daugeliui VRP variantų, „DIMACS“ konkurse [DIM22] parodęs geriausių rezultatų VRPTW uždavinyje [Koo+22], ir kurio modifikuotas variantas [Jia+22] pasirodė geriausiai CVRP uždavinyje. Šis algoritmas yra pritaikytas CVRP, VRPTW, GVRP [Lat25a], CluVRP, SoftCluVRP [Lat25b].

Šio **darbo tikslas** – išlygiagretinti hibridinio genetinio paieškos algoritmą, skirtą transporto maršrutų optimizavimo uždaviniams spręsti, siekiant sumažinti vykdymo laiką neprarandant ar net pagerinant sprendinių kokybę.

Uždaviniai:

1. Išsirinkti duomenų rinkinį, pagal kurį galima būtų testuoti ir analizuoti sprendinius.
2. Išanalizuoti, kaip veikia HGS algoritmas.
3. Atrinkti paralelizuojamas dalis, kurias galima pakeisti lygiagrečiomis.
4. Palyginti rezultatus su literatūroje aprašytais pažangiausiais algoritmais.

1. Transporto maršrutų optimizavimo uždaviniai

1.1. Tikslūs ir apytiksliai metodai

Nors egzistuoja įrankiai, kurie pasiteklia tikslūs metodai (pavyzdžiui „Google or-tools“ [PF25]), kadangi šis uždavinys priklauso *NP-Hard* sudėtingumo klasei, visgi dominuoja heuristikomis ir metaheuristikomis grįsti algoritmai, nes šie beveik optimalius sprendinius suranda per greitesnį laiko tarpą sunaudodami mažiau resursų. Tikslūs metodai su ypač dideliais kiekiais duomenų tampa nepraktiški. Metaheuristiciniai algoritmai išsiskiria šioje uždavinių klasėje kaip efektyviausi, pasižymintys žemu algoritmo vykdymo laiku ir aukšta uždavinių rezultatų kokybe.

Šiai problemai egzistuoja heuristiniai ir metaheuristiciniai (Aukštesnio lygio strategija, kuris diriguoja, kurias heuristikas pritaikyti, kad efektyviau atrasti sprendinius) algoritmai. Keli dominuojantys pavyzdžiai [Ada+24]

- „Adaptive Large Neighborhood Search“ ir „Hybrid Adaptive Large Neighborhood Search“
- „Hybrid Genetic Search (HGS)“
- „Simulated Annealing Algorithm (SAA)“
- „Ant colony optimization (ACO)“

1.2. VRP variacijos

Praktikoje taikomos keletas VRP variacijų (CVRP, VRPTW, MDPVRP, PVRP ir kt.). Jos įveda papildomus apribojimus maršrutų ilgiui, transporto priemonių panaudojimo laikui ir talpai, ar prideda papildomas sąlygas:

- naudojamos transporto priemonės turi limituotą talpą (CVRP);
- visi klientai turi gali būti aplankyti tik specifinėmis darbo valandomis (VRPTW);
- keli depai iš kurių galima pradėti maršrutą (MDVRP);
- maršrutai planuojami per kelias dienas, t.y. vieni klientai gali būti aplankyti vieną dieną, o kiti kitą. (Periodic VRP);
- kt.

Šis darbas atsižvelgia tik į CVRP uždavinį.

1.3. CVRP

CVRP nagrinėjamas grafas $G = (V, E)$, kuriame $v_0 \in V$ žymi depą, kuris turi m transporto priemonių, o likusios viršūnės $\{v_1, \dots, v_{|V|}\}$ atitinka klientus, kuriuos reikia aplankyti. Kiekviena briauna $(i, j) \in E$ reiškia galimybę keliauti tarp vietų i ir j su kaina $c_{i,j}$ – euklidinis atstumas tarp vietų i ir j . CVRP reikia surasti sprendinį, kuriame panaudotos ne daugiau kaip K transporto priemonių, prasidedančių ir pasibaigiančių depe, taip, kad kiekvienas klientas būtų aplankytas vieną kartą ir bendras klientų paklausos dydis bet kuriame maršrute neviršytų transporto priemonės talpos Q , o bendras transporto priemonių nuvažiuotas atstumas – kaina (žr. 2-a lygtis) kiek įmanoma mažesnis.

$$c_{i,j} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2} \quad (1)$$

$$\text{Sprendinio kaina} = \sum_{k=1}^K \sum_{i=0}^{|V|} \sum_{j=0}^{|V|} c_{i,j} x_{i,j,k}$$

$$x_{i,j,k} = 1 \text{ Indikatorinė funkcija, kuri} \quad (2)$$

lygi 1, jei transporto priemonė k ($1 \leq k \leq K$)
keliauja nuo kliento i iki kliento j ,
lygi 0 priešingu atveju

Lyginant transporto maršrutų optimizavimo uždavinio sprendinius taip pat naudojama spraga (*angl. gap*), kuris nusako atstumą nuo geriausio sprendinio išreikštas procentais Lygt. 3.

$$\text{Spraga} = \left(\frac{Z_s - Z_{\text{BKS}}}{Z_{\text{BKS}}} \right) \cdot 100\% \quad (3)$$

Z_s = Pasirinkto algoritmo sprendinio kaina

Z_{BKS} = Geriausio sprendinio kaina

2. HGS algoritmo veikimas

Pirma aprašytas "A Hybrid Genetic Algorithm for Multidepot and Periodic Vehicle Routing Problems" [Vid+12] (2012) skirtas spręsti MDPVRP. Patobulintas per daugelį iteracijų: [Vid+14], [Vid+16], [Vid17], [Vid+21], [Vid22] ir pritaikytas CVRP. Pastarasis variantas vadinamas HGS-CVRP.

Genetiniai algoritmai imituoja evoliucijos procesą. Populiacija yra aibė, kurią sudaro individai (t.y. užduoties sprendiniai). Šie algoritmai naudoja įvairius kryžminimo operatorius, kurie iš kelių individų populiacijoje sukuria naują, mutuotą individą ir prideda prie populiacijos (1-ame pavyzdyje 1, 2 ir 4 žingstis). Prastos kokybės ir panašūs individai (sprendiniai) vykdymo eigoje yra pašalinami iš populiacijos.


Genetinis hibridinis paieškos algoritmas prie genetinio komponento prideda pagerinimo žingsnį – vietinę paiešką (*angl. local search*), kuri po kryžminimo žingsnio yra pritaikoma naujam individui, kad pagerinti gautą individo kokybę (1-ame pavyzdyje 3 žingstis). Vietinei paieškai pasiteklėti *relocate*, *swap*, *2-opt*, *2-opt** ir *swap** algoritmai.

TODO Trumpai apie Swap* (Vidal 2022, HGS-CVRP):

- Idėja: parenkami du klientai (v) ir (v') iš skirtingų maršrutų (r) ir (r'); abu išimami ir kiekvienas įterpiamas į bet kurią kito maršruto poziciją. Tai yra didesnė kaimynystė nei klasikinis Swap, nes įterpimo pozicijos nėra fiksuotos.
- Dydis labai didelis (straipsnis mini ($\Theta(n^4)$) galimų judesių), bet pateikiama teorema: geriausias įterpimas yra arba "į vietą" išimto kliento, arba vienoje iš 3 geriausių iš anksto apskaičiuotų įterpimo pozicijų. Todėl kiekvienai maršrutų porai iš anksto randamos top-3 pozicijos ir tik tada tikrinamos poros (v, v') → gaunama sub-kvadratinė paieška ir realiai panašus laikas kaip Swap/Relocate/2-Opt*.

Apie pagreitėjimą / poveikį HGS:

- Straipsnis teigia, kad HGS-CVRP (su Swap*) pasiekia tą pačią sprendinių kokybę kaip HGS-2012 per dalį laiko ir konvergencijos grafikuose lenkia HGS-2012 visais laiko momentais (1–100% laiko limitu).
- Analizėje Swap* sudaro $\leq 32\%$ vietinės paieškos CPU laiko, bet duoda 15% visų patobulinimų ir ypač padeda vėlyvose paieškos stadijose.
- Konkretaus vieno "x kartų greičiau" skaičiaus tekstas nenurodo; greitėjimas demonstruojamas konvergencijos grafikuose ir teiginiu "fraction of computational time".



1 pav. HGS veikimas [Vid22]

Tėvų atranka vykdoma dvejetainiu turnyru, kur paskaičiuojamas tinkamumas (*angl. fitness*) t. y. sprendinio kainos ir įvairovės (*broken-pairs* atstumo) suma ir išrenkami didžiausią tinkamumą turintys individai; populiacija palaikoma kaip įvykdomų ir neįvykdomų subpopuliacijų rinkinys, o baudos parametrai tikslinami, kad būtų išlaikytas įvykdomų ir neįvykdomų sprendinių santykis [Vid22], [Vid+12]. Palaikant neįvykdomus (*angl. infeasible*) ir įvykdomus (*angl. feasible*) sprendinius, išlaikoma populiacijos įvairovė (*angl. diversity*), kuri leidžia išvengti lokalsios minimos (*angl. local minima*) iteruojant per sprendinius.

Dar vienas svarbus elementas yra populiacijos valdymas. Tai individų iš įvykdomų ir neįvykdomų sprendinių subpopuliacijų blogiausių (t.y. didžiausios kainos ir panašūs individai) pašalinimas kas numatytą iteracijų skaičių pagal baudos parametrus, kurie patys yra tikslinami genetinio algoritmo eigos metu, tai palaiko įvairovę ir mažina sprendinių kainą [Vid+12], [Vid22].

- 1 Sugeneruoti pradinę populiaciją ir pagerinti ją vietine paieška
- 2 **Kol** iteracijų be pagerėjimo skaičius ir vykdymo laikas neviršija limitų:
- 3 Pasirinkti tėvinius individus (dvejetainis turnyras (*angl. binary tournament*))
- 4 Atlikti kryžminimą (*angl. crossover*)
- 5 Išmokyti naują individą (vietinė paieška)
- 6 Įterpti išmokytą individą į atitinkamą subpopuliaciją
- 7 **Jeigu** individas neįvykdomas:
- 8 Su 50% tikimybe bandyti sutaisyti individą ir įtraukti į atitinkamą subpopuliaciją
- 9 **Jeigu** pasiektas maksimalus aibės dydis:
- 10 pašalinti blogiausius ir neįvairius individus iš populiacijos
- 11 Patikslinti baudos parametrus (*angl. penalty parameters*)
- 12 Grąžinti geriausią įvykdomą individą


2 pav. HGS algoritmo pseudokodas [Vid+12]

3. Literatūros analizė

[AS20] siūlo genetinį algoritmą, kuris pilnai vykdomas GPU (CUDA): GPU branduoliai atlieka pradinę populiacijos generaciją, kaštų skaičiavimą, kryžminimą, mutaciją ir *2-opt* vietinę paiešką. Sprendinių kokybei gerinti taikomos *2-opt* ir artimiausio kaimyno heuristikos, o autoriai pateikia CPU ir GPU versijų palyginimą bei parodo, kad *2-opt* reikšmingai mažina spragą, nors didina vykdymo laiką.

[YT21] pasitelkia GPU lygiagretinimui. Kiekvienam maršrutui skiriama atskira GPU gija, kuri vykdo vietinės paieškos žingsnį naudojant GPU. Šiuo metodu pilnas resursų išnaudojimas priklauso nuo to, ar sukurtų maršrutų skaičius sutampa su gijų skaičiumi. Atvejai, kai vietinės paieškos žingsniai modifikuoja kitų maršrutų sprendinį, gijos įrašo savo sprendinius į atskirą masyvą, kuris vėliau yra redukuojamas į vieną sprendinį, pasirenkant geriausią sprendinį. Analogiškai, vėlesniame žingsnyje kiekvienam klientui priskiriama gija. Kiekviena gija apskaičiuoja pagerėjimą ar pablogėjimą apsikeitus vietą maršrute su kitu klientu. Vietinė paieška apima *swap* ir *relocate* (tarp maršrutų) bei *2-opt*, *or-opt*, *3-opt* (maršruto viduje) heuristikas, o pradinis sprendinys konstruojamas artimiausio kaimyno metodu.

[LHW25] lygiagretinimui vietinės paieškos algoritmą išreiškia tenzorių operatoriais, tai leidžia HGS vykdymą perkelti ant GPU. Taip pagreitintas vietinės paieškos operatorius. Tačiau [LHW25] pasiūlytas metodas nėra pritaikomas HGS su *swap**. „Dabartinė sprendinių reprezentacija per tensorius neleidžia lengvai įgyvendinti apkarpymo strategijų kaimynysčių sumažinimo technikų, kurie dažnai yra naudojami vietinės paieškos grįžtais algoritmais [LHW25, 33].“¹




3 pav. Lygiagretintas HGS pagal [SND23]

[SND23] HGS pritaiko CVRPPD, perkelia tėvų pasirinkimo (*angl. selection*), kryžminimo (*angl. crossover*) ir taisymo (*angl. repair*) žingsnius į atskiras gijas. Kiekviena gija papildomai atlieka vietinę paiešką (*2-opt*, *relocate*, *swap*) pasitelkiant GPU, tačiau nepasitelkia *swap** heuristika, kuri pagal [Vid22] padeda surasti aukštesnės kokybės sprendinius.

¹the current design of the tensor representation of solutions doesn't support easy implementation of pruning strategies and neighborhood reduction techniques that are often used in local search-based routing algorithms.

Priešingai nei dauguma implementacijų [Mun+23] naudoja grafų duomenų struktūras, panaudojami tik *2-opt* ir arčiausio kaimyno heuristikos (*angl. nearest-neighbor*). Šios heuristikos pritaikytos vykdymui GPU aplinkoje naudojant CUDA.



4 pav. HGS su salų modeliu [Jam+25]

[Jam+25] aprašo *PHGS* (*angl. Parallel Hybrid Genetic Search*), kur kombinuoja HGS su salų (*angl. islands*) modeliu, aprašytu [Rez+24]. 4-ame pavyzdyje parodytas šio algoritmo veikimas. Kiekviena gija vykdo tą patį HGS algoritmą, pridėdamas individų migracijos žingsnis, kuris leidžia keistis sprendiniais tarp gijų.

Nemaža dalis literatūros yra aprašiusi tik greitinimą ant GPU. Vis dėlto nemaža dalis pagreitinimų pritaikomumas HGS-CVRP (su *swap** operatoriumi) išlieka atvira problema.

4. HGS-CVRP lygiagretinimas

Paimta [Vid22] HGS algoritmo implementacija², kuri naudojama kaip pagrindas lygiagretinimui.

Daugiausiai laiko užima vietinės paieškos žingsnis [Jam+25], šio darbo autoriaus atliktais matavimais vietinė paieška užima 85% vykdymo laiko. Todėl siekiant sumažinti viso HGS algoritmo vykdymo laiką šį žingsnį yra labiausiai verta lygiagretinti.


Lygiagretinimas realizuotas „OpenMP“ pagrindu. Kiekvienoje iteracijoje nuosekliai veikiančioje algoritmo dalyje parenkami $2N$ tėviniai individai ir iš jų sugeneruojami N palikuonių, o vietinė paieška vykdoma lygiagrečiai – kiekviena gija apdoroja po vieną palikuonį.

Sinchronizacija vyksta per „OpenMP“ barjerus: po lygiagrečios vietinės paieškos ir taisymo etapų visos nuoseklios algoritmo sekcijos vykdomas blokuojams ligi tol kol visos gijos baigia mokymo etapą. Nauji individai nuosekliai įterpiami į bendrą populiaciją.

Toks lygiagretinimo būdas išvengia sinchronizacijos kaštų dėl bendrų duomenų rašymo prieigos prie bendrų duomenų. Pav. 5 pavyzdys pavaizduoja kaip kiekvienas algoritmo žingsnis modifikuoja bendrus duomenis.

Papildomai, šis lygiagretinimo būdas leidžia išlaikyti swap* operatorių, kuris kitose lygiagretintose HGS versijose buvo pašalintas [Jam+25, SND23].

Šis sprendimas taip pat leidžia išlaikyti HGS populiacijos valdymą vienoje vietoje ir yra paprastesnis nei GPU pagrįstas operatorių perrašymas ar salų modelio migracija [LHW25], [Jam+25].



5 pav. Bendros atminties rašymo etapai

Vis dėlto greیتaveiką riboja nuoseklūs žingsniai. kryžminimo, baudų parametrų tikslinimo bei populiacijos valdymo žingsniai atliekami nuosekliai, todėl dalį laiko visos gijos, apart vienos,

²Nuolatinė repozitorijos nuoroda <https://github.com/vidalt/HGS-CVRP/tree/1a927955cd2861a29d978f0d359d6e647db9319c>

neatlieką jokių veiksmų. Papildomai, prieš populiacijos valdymo žingsnį visos gijos privalo baigti vietinę paiešką, lėtai veikianti gija gali užtęsti visos iteracijos vykdymo laiką.

5. Lygiagretintos ir nuoseklios programos palyginimas

5.1. Metodika

HGS ir kiti iteratyvūs algoritmai sustoja tik, kai pasiekiamas tam tikras kriterijus. HGS atveju tai iteracijų skaičius be pagerėjimo arba veikimo laikas. Kadangi šie parametrai gali būti laisvai parinkti, pasirinkus pakankamai aukštas ribas algoritmo veikimo laikas gali tęstis begalo.

Dėl rezultatų palyginamumo pasirinkta naudoti [Vid22] aprašytus duomenų rinkinius ([Uch+17]) ir metodiką: „Mes stebime kiekvieno algoritmo pažangą iki laiko ribos $T_{\max} = n \cdot 240 / 100$ sekundžių, kur n reiškia klientų skaičių. Todėl mažiausias atvejis su 100 klientais vykdomas 4 minutes, o didžiausias atvejis su 1000 klientų vykdomas 40 minučių. Kiekvieno veikimo metu mes užregistruojame geriausią sprendimo vertę po 1%, 2%, 5%, 10%, 15%, 20%, 30%, 50%, 75% ir 100% laiko ribos, kad galėtume įvertinti algoritmų našumą skirtinguose paieškos etapuose [Vid22, 6].“³

Vykdomo duomenys surinkti paleidžiant lygiagretintą ir palyginimui originalią HGS-CVRP programą ant „Intel® Xeon® Gold 6252“ procesoriaus. Šiam eksperimentui iteracijų skaičius be pagerėjimo laikytas begaliniu, o $T_{\max} = n \cdot \frac{24}{100}$, t.y. 10 kartų mažesnis negu [Vid22], kad būtų sutilpta į MIF STSC resursų limitus. Rezultatuose naudojami 5 HGS paleidimų kartų sprendinių vykdymo laiko ir kainos vidurkiai. Lygiagretintos programos versija patalpinta „Codeberg“ repozitorijoje⁴.

Naudoti algoritmo ir vykdymo parametrai pateikti 1-oje lentelėje. Dauguma parametrų palikti pagal numatytas reikšmes, o eksperimente fiksuoti gijų skaičius, atsitiktinės atrankos sėkla (*angl. randomization seed*) ir laiko limitas.

Lyginant lygiagrečią ir nuoseklią versijas naudojamas realus laikas (*angl. wall-clock*), vietoje procesoriaus laiko (*angl. CPU-time*), nes daugiagijės versijos CPU-laiko matavimas parodytų kiekvieno procesoriaus vykdymo laikų sumą ir neatitiktų realaus vykdymo laiko.


Palyginimui naudoti geriausių sprendinių rinkinys⁵.

³We monitor each algorithm's progress up to a time limit of $T_{\max} = n \cdot 240 / 100$ seconds, where n represents the number of customers. Therefore, the smallest instance with 100 clients is run for 4 minutes, whereas the largest instance containing 1000 clients is run for 40 minutes. During each run, we record the best solution value after 1%, 2%, 5%, 10%, 15%, 20%, 30%, 50%, 75%, and 100% of the time limit to measure the performance of the algorithms at different stages of the search.


⁴<https://codeberg.org/Dom/HGS-CVRP/src/commit/411e391ffefac9a308d28e280194d65004d8332c>

⁵<https://galgos.inf.puc-rio.br/cvrplib/index.php/en/instances>, prieigos data: 2026-01-07

5.2. Rezultatai



6 pav. Vidutinė sprendinių spraga pagal gijų skaičių. Spraga apskaičiuojama pagal BKS, o x ašis rodo vykdyimo laiką procentais.



7 pav. Sprendimo kokybės santykis tarp viengijio ir N gijų sprendimų (1 gijos spraga / N gijos spraga) priklausomai nuo vykdyimo laiko.

Su vis didesniu gijų skaičiumi vidutinė sprendinių spraga yra mažesnė ypač . Galutiniame laiko momente (Uchoa 2017 X-n rinkinys [Uch+17]) vidutinė spraga sumažėja nuo 0.42% (1 gija) iki 0.23% (16 gijų), o 8 gijų atveju siekia 0.25%.

Santykio grafikas rodo didėjančią naudą bėgant laikui: 1/8 santykis siekia 1.50 po 10% laiko ir 1.68 pabaigoje, o 1/16 atitinkamai 1.54 ir 1.83. Vis dėlto skirtumas tarp 8 ir 16 gijų pabaigoje yra tik apie 0.02 procentinio punkto, todėl grąža mažėja didinant gijų skaičių.

Palyginus su [Jam+25], 16 gijų atvejis rodo panašų pagerėjimą (1.8 karto) galutinio laiko momentu, tačiau tiesioginis palyginimas ribotas dėl skirtingo $T_{\max}$ ir aparatinės įrangos. Kadangi šiame darbe $T_{\max}$ sumažintas 10 kartų, absoliutūs spragos dydžiai gali skirtis, bet tendencijos sutampa.

Rezultatai ir išvados

Rezultatai

1. Parinktas duomenų rinkinys, pagal kurį galima testuoti ir analizuoti sprendinius.
2. Atlikta HGS algoritmo veikimo analizė ir aprašyta HGS-CVRP specifika.
3. Įgyvendintas vietinės paieškos lygiagretinimas ir aprašyta lygiagretinimo schema.
4. Pateiktas rezultatų palyginimas.

Išvados

Priedai

1. Priedas. Eksperimento parametrai

1 lentelė. Eksperimento parametrai

Parametras	Reikšmė
Algoritmo parametrai	
nbGranular (granuliarumo parametras)	20
mu (min populiacijos dydis)	25
lambda (generacijos dydis)	40
nbElite (elitiniai individai)	4
nbClose (artimiausi individai)	5
nbIterPenaltyManagement (baudos parametru atnaujinimo periodas)	50
targetFeasible (tikslinė įvykdomų sprendinių dalis)	0.2
penaltyIncrease / penaltyDecrease (baudos didinimo/mažinimo koeficientai)	1.2 / 0.85
useSwapStar (swap* kaimynystės naudojimas)	1 (naudojama, kai pateiktos koordinatės)
Vykdyimo parametrai	
nbIter (iteracijų limitas)	0 (iteracijų limitas netaikomas)
$T_{\max}$ (laiko limitas)	$n \cdot \frac{24}{100}$ s
Sėklos (atsitiktinių skaičių generatoriaus pradinės reikšmės)	1-5
Gijų skaičius p (paralelizavimo lygis)	1, 2, 4, 8, 16
Traces (progreso fiksavimo žingsnis)	kas 1% laiko limitu (wall-clock)

2. Priedas. Vidutinė spraga pagal vykdymo laiką ir gijų skaičių

2 lentelė. Vidutinė spraga (%) pagal vykdymo laiką ir gijų skaičių

Vykdyimo laikas (%)	1 gija ⁶	2 gijos	4 gijos	8 gijos	16 gijos
	Tarpas (%)	Tarpas (%)	Tarpas (%)	Tarpas (%)	Tarpas (%)
0	-	-	-	-	-
1	2.77%	2.72%	2.66%	2.62%	2.59%
2	2.3%	2.16%	2.06%	1.95%	1.88%
3	2%	1.9%	1.72%	1.57%	1.53%
4	1.77%	1.68%	1.48%	1.35%	1.31%
5	1.62%	1.51%	1.32%	1.19%	1.16%
6	1.5%	1.39%	1.2%	1.07%	1.04%
7	1.41%	1.3%	1.11%	0.99%	0.96%
8	1.33%	1.21%	1.04%	0.92%	0.89%
9	1.27%	1.15%	0.97%	0.86%	0.84%
10	1.21%	1.09%	0.93%	0.81%	0.79%
11	1.17%	1.04%	0.88%	0.77%	0.74%
12	1.12%	1%	0.85%	0.73%	0.7%
13	1.08%	0.96%	0.81%	0.7%	0.67%

⁶Naudota originali realizacija

Vykdymo laikas (%)	1 gija ⁷	2 gijos	4 gijos	8 gijos	16 gijos
	Tarpas (%)	Tarpas (%)	Tarpas (%)	Tarpas (%)	Tarpas (%)
14	1.05%	0.93%	0.78%	0.67%	0.64%
15	1.01%	0.91%	0.75%	0.65%	0.62%
16	0.99%	0.88%	0.73%	0.63%	0.6%
17	0.96%	0.86%	0.71%	0.61%	0.58%
18	0.94%	0.84%	0.69%	0.6%	0.56%
19	0.92%	0.81%	0.67%	0.58%	0.54%
20	0.9%	0.79%	0.65%	0.56%	0.52%
21	0.88%	0.78%	0.64%	0.55%	0.51%
22	0.86%	0.76%	0.62%	0.54%	0.49%
23	0.84%	0.74%	0.61%	0.53%	0.48%
24	0.82%	0.73%	0.6%	0.51%	0.47%
25	0.81%	0.71%	0.58%	0.5%	0.46%
26	0.8%	0.7%	0.57%	0.49%	0.45%
27	0.78%	0.69%	0.56%	0.48%	0.44%
28	0.77%	0.68%	0.55%	0.47%	0.43%
29	0.76%	0.66%	0.54%	0.47%	0.42%
30	0.75%	0.65%	0.53%	0.46%	0.41%
31	0.74%	0.64%	0.52%	0.45%	0.4%
32	0.73%	0.63%	0.51%	0.44%	0.4%
33	0.72%	0.62%	0.51%	0.44%	0.39%
34	0.71%	0.61%	0.5%	0.43%	0.38%
35	0.69%	0.6%	0.5%	0.43%	0.38%
36	0.69%	0.6%	0.49%	0.42%	0.37%
37	0.68%	0.59%	0.48%	0.41%	0.37%
38	0.67%	0.58%	0.47%	0.41%	0.36%
39	0.66%	0.57%	0.47%	0.4%	0.36%
40	0.65%	0.57%	0.46%	0.4%	0.35%
41	0.64%	0.56%	0.46%	0.39%	0.35%
42	0.64%	0.55%	0.45%	0.39%	0.34%
43	0.63%	0.55%	0.45%	0.38%	0.34%
44	0.62%	0.54%	0.44%	0.38%	0.33%
45	0.62%	0.54%	0.43%	0.37%	0.33%
46	0.61%	0.53%	0.43%	0.37%	0.33%
47	0.6%	0.53%	0.42%	0.36%	0.32%
48	0.6%	0.52%	0.42%	0.36%	0.32%
49	0.59%	0.52%	0.41%	0.36%	0.32%
50	0.58%	0.51%	0.41%	0.35%	0.32%
51	0.58%	0.51%	0.41%	0.35%	0.31%
52	0.57%	0.5%	0.4%	0.35%	0.31%
53	0.56%	0.5%	0.4%	0.34%	0.31%
54	0.56%	0.49%	0.4%	0.34%	0.3%

⁷Naudota originali realizacija

Vykdymo laikas (%)	1 gija ⁸	2 gijos	4 gijos	8 gijos	16 gijos
	Tarpas (%)	Tarpas (%)	Tarpas (%)	Tarpas (%)	Tarpas (%)
55	0.55%	0.49%	0.39%	0.34%	0.3%
56	0.55%	0.48%	0.39%	0.33%	0.3%
57	0.54%	0.48%	0.38%	0.33%	0.3%
58	0.54%	0.48%	0.38%	0.33%	0.29%
59	0.53%	0.47%	0.38%	0.33%	0.29%
60	0.53%	0.47%	0.37%	0.32%	0.29%
61	0.53%	0.47%	0.37%	0.32%	0.29%
62	0.52%	0.46%	0.37%	0.32%	0.28%
63	0.52%	0.46%	0.37%	0.32%	0.28%
64	0.51%	0.46%	0.36%	0.31%	0.28%
65	0.51%	0.45%	0.36%	0.31%	0.28%
66	0.5%	0.45%	0.36%	0.31%	0.28%
67	0.5%	0.45%	0.35%	0.31%	0.27%
68	0.5%	0.44%	0.35%	0.3%	0.27%
69	0.49%	0.44%	0.35%	0.3%	0.27%
70	0.49%	0.43%	0.35%	0.3%	0.27%
71	0.49%	0.43%	0.34%	0.29%	0.27%
72	0.48%	0.43%	0.34%	0.29%	0.26%
73	0.48%	0.43%	0.34%	0.29%	0.26%
74	0.48%	0.42%	0.34%	0.29%	0.26%
75	0.47%	0.42%	0.33%	0.29%	0.26%
76	0.47%	0.42%	0.33%	0.28%	0.26%
77	0.47%	0.41%	0.33%	0.28%	0.26%
78	0.47%	0.41%	0.33%	0.28%	0.26%
79	0.46%	0.41%	0.32%	0.28%	0.25%
80	0.46%	0.41%	0.32%	0.28%	0.25%
81	0.46%	0.4%	0.32%	0.27%	0.25%
82	0.45%	0.4%	0.32%	0.27%	0.25%
83	0.45%	0.4%	0.32%	0.27%	0.25%
84	0.45%	0.4%	0.32%	0.27%	0.25%
85	0.45%	0.39%	0.31%	0.27%	0.25%
86	0.44%	0.39%	0.31%	0.27%	0.24%
87	0.44%	0.39%	0.31%	0.27%	0.24%
88	0.44%	0.39%	0.31%	0.26%	0.24%
89	0.44%	0.39%	0.31%	0.26%	0.24%
90	0.44%	0.38%	0.3%	0.26%	0.24%
91	0.43%	0.38%	0.3%	0.26%	0.24%
92	0.43%	0.38%	0.3%	0.26%	0.24%
93	0.43%	0.38%	0.3%	0.26%	0.23%
94	0.43%	0.37%	0.3%	0.26%	0.23%
95	0.43%	0.37%	0.29%	0.25%	0.23%

⁸Naudota originali realizacija

Vykdyto laikas (%)	1 gija ⁹	2 gijos	4 gijos	8 gijos	16 gijos
	Tarpas (%)	Tarpas (%)	Tarpas (%)	Tarpas (%)	Tarpas (%)
96	0.42%	0.37%	0.29%	0.25%	0.23%
97	0.42%	0.37%	0.29%	0.25%	0.23%
98	0.42%	0.37%	0.29%	0.25%	0.23%
99	0.42%	0.36%	0.29%	0.25%	0.23%
100	0.42%	0.36%	0.29%	0.25%	0.23%

3. Priedas. Spragos santykis tarp viengijės ir daugiagijės versijų

3 lentelė. Spragos santykis (1 gija / N gijų) pagal vykdyto laiką

Vykdyto laikas (%)	2 gijos	4 gijos	8 gijos	16 gijos
	Santykis	Santykis	Santykis	Santykis
0	-	-	-	-
1	1.02	1.04	1.06	1.07
2	1.06	1.12	1.18	1.22
3	1.05	1.16	1.27	1.31
4	1.06	1.2	1.31	1.35
5	1.07	1.22	1.36	1.4
6	1.08	1.25	1.4	1.44
7	1.09	1.28	1.43	1.48
8	1.1	1.28	1.45	1.49
9	1.11	1.3	1.47	1.52
10	1.11	1.31	1.5	1.54
11	1.12	1.33	1.52	1.57
12	1.12	1.33	1.53	1.6
13	1.12	1.34	1.54	1.61
14	1.12	1.34	1.56	1.63
15	1.12	1.35	1.56	1.64
16	1.12	1.35	1.56	1.66
17	1.12	1.36	1.57	1.67
18	1.12	1.36	1.58	1.69
19	1.13	1.37	1.58	1.71
20	1.13	1.38	1.6	1.73
21	1.13	1.38	1.6	1.73
22	1.13	1.38	1.6	1.74
23	1.13	1.38	1.59	1.74
24	1.13	1.38	1.6	1.75
25	1.13	1.39	1.6	1.76
26	1.14	1.4	1.62	1.77
27	1.14	1.4	1.62	1.77
28	1.14	1.4	1.62	1.78
29	1.14	1.4	1.63	1.8

⁹Naudota originali realizacija

Vykdymo laikas (%)	2 gijos	4 gijos	8 gijos	16 gijos
	Santykis	Santykis	Santykis	Santykis
30	1.14	1.41	1.63	1.81
31	1.15	1.41	1.64	1.83
32	1.15	1.41	1.64	1.83
33	1.15	1.42	1.64	1.84
34	1.15	1.41	1.64	1.84
35	1.15	1.4	1.63	1.84
36	1.15	1.41	1.64	1.85
37	1.15	1.4	1.63	1.85
38	1.15	1.4	1.63	1.85
39	1.15	1.41	1.64	1.85
40	1.15	1.41	1.65	1.85
41	1.15	1.41	1.65	1.85
42	1.15	1.41	1.66	1.86
43	1.15	1.41	1.65	1.86
44	1.15	1.41	1.65	1.86
45	1.15	1.42	1.65	1.86
46	1.14	1.42	1.65	1.86
47	1.14	1.42	1.65	1.85
48	1.14	1.42	1.65	1.85
49	1.14	1.42	1.65	1.85
50	1.14	1.42	1.64	1.85
51	1.14	1.42	1.64	1.84
52	1.13	1.42	1.64	1.84
53	1.13	1.41	1.64	1.83
54	1.13	1.41	1.64	1.84
55	1.13	1.41	1.64	1.84
56	1.13	1.41	1.64	1.84
57	1.13	1.41	1.63	1.84
58	1.13	1.42	1.64	1.84
59	1.13	1.42	1.64	1.84
60	1.13	1.42	1.64	1.84
61	1.12	1.42	1.64	1.83
62	1.13	1.42	1.64	1.84
63	1.13	1.42	1.64	1.83
64	1.12	1.41	1.64	1.83
65	1.12	1.41	1.64	1.83
66	1.13	1.42	1.64	1.83
67	1.13	1.42	1.64	1.83
68	1.13	1.42	1.64	1.83
69	1.13	1.41	1.64	1.83
70	1.13	1.42	1.65	1.83
71	1.13	1.42	1.65	1.83

Vykdymo laikas (%)	2 gijos	4 gijos	8 gijos	16 gijos
	Santykis	Santykis	Santykis	Santykis
72	1.13	1.42	1.66	1.83
73	1.13	1.42	1.66	1.83
74	1.13	1.42	1.66	1.83
75	1.13	1.42	1.66	1.82
76	1.13	1.42	1.67	1.83
77	1.13	1.43	1.67	1.83
78	1.13	1.43	1.67	1.83
79	1.13	1.43	1.67	1.83
80	1.13	1.42	1.67	1.82
81	1.13	1.42	1.67	1.82
82	1.13	1.42	1.67	1.82
83	1.13	1.43	1.67	1.82
84	1.13	1.43	1.67	1.82
85	1.13	1.43	1.67	1.82
86	1.13	1.43	1.67	1.83
87	1.14	1.43	1.67	1.83
88	1.14	1.43	1.67	1.83
89	1.14	1.44	1.68	1.84
90	1.14	1.44	1.67	1.84
91	1.14	1.44	1.67	1.84
92	1.14	1.44	1.67	1.83
93	1.14	1.45	1.68	1.83
94	1.14	1.44	1.67	1.83
95	1.14	1.44	1.68	1.83
96	1.15	1.45	1.68	1.84
97	1.15	1.45	1.68	1.84
98	1.15	1.45	1.68	1.84
99	1.15	1.44	1.68	1.83
100	1.15	1.44	1.68	1.83

4. Priedas. Vidutinės pasiektos sprendimų kainos ir tarpas galutiniu laiko momentu

4 lentelė. Vidutinės pasiektos sprendimų kainos ir tarpas galutiniu laiko momentu

Uždavinys	1 gija ¹⁰		2 gijos		4 gijos		8 gijos		16 gijos	
	Avg	Spraga	Avg	Spraga	Avg	Spraga	Avg	Spraga	Avg	Spraga
X-n101-k25	27591	0%	27591	0%	27591	0%	27591	0%	27591	0%
X-n106-k14	26415.6	0.2%	26402.6	0.15%	26396.8	0.13%	26386.6	0.09%	26392	0.11%
X-n110-k13	14971	0%	14971	0%	14971	0%	14971	0%	14971	0%
X-n115-k10	12747	0%	12747	0%	12747	0%	12747	0%	12747	0%
X-n120-k6	13332	0%	13332	0%	13332	0%	13332	0%	13332	0%

¹⁰Naudota originali realizacija

Uždavinys	1 gija ¹¹		2 gijos		4 gijos		8 gijos		16 gijos	
	Avg	Spraga	Avg	Spraga	Avg	Spraga	Avg	Spraga	Avg	Spraga
X-n125-k30	55541.8	0.01%	55540.4	0%	55541.8	0.01%	55539	0%	55540.4	0%
X-n129-k18	28940	0%	28940	0%	28940	0%	28940	0%	28940	0%
X-n134-k13	10924.8	0.08%	10916.8	0.01%	10916	0%	10919.4	0.03%	10916	0%
X-n139-k10	13590	0%	13590	0%	13590	0%	13590	0%	13590	0%
X-n143-k7	15702.2	0.01%	15700	0%	15700	0%	15700	0%	15700	0%
X-n148-k46	43448	0%	43448	0%	43448	0%	43448	0%	43448	0%
X-n153-k22	21225.6	0.03%	21227	0.03%	21225	0.02%	21225	0.02%	21225	0.02%
X-n157-k13	16876	0%	16876	0%	16876	0%	16876	0%	16876	0%
X-n162-k11	14138	0%	14138	0%	14138	0%	14138	0%	14138	0%
X-n167-k10	20561.2	0.02%	20557	0%	20557	0%	20557	0%	20557	0%
X-n172-k51	45607	0%	45607	0%	45607	0%	45607	0%	45607	0%
X-n176-k26	47812	0%	47812	0%	47813	0%	47812	0%	47812	0%
X-n181-k23	25572	0.01%	25569.8	0%	25569.6	0%	25569	0%	25569.8	0%
X-n186-k15	24145	0%	24145.4	0%	24145	0%	24145	0%	24145	0%
X-n190-k8	17059.6	0.47%	17079.6	0.59%	17008	0.16%	16996.8	0.1%	16992.8	0.08%
X-n195-k51	44234.6	0.02%	44235	0.02%	44236.8	0.03%	44229.8	0.01%	44238.2	0.03%
X-n200-k36	58618.2	0.07%	58624.4	0.08%	58603.8	0.04%	58604.8	0.05%	58598	0.03%
X-n204-k19	19568	0.02%	19565	0%	19565	0%	19565	0%	19565	0%
X-n209-k16	30677.4	0.07%	30672	0.05%	30666.6	0.03%	30657.2	0%	30663.6	0.02%
X-n214-k11	10879.2	0.21%	10872.8	0.15%	10870.8	0.14%	10868.4	0.11%	10867.4	0.11%
X-n219-k73	117609.6	0.01%	117603.8	0.01%	117605.2	0.01%	117597.2	0%	117600.8	0%
X-n223-k34	40458.4	0.05%	40481.8	0.11%	40475.4	0.09%	40482.2	0.11%	40458.2	0.05%
X-n228-k23	25743	0%	25746.8	0.02%	25749	0.03%	25743.6	0.01%	25743	0%
X-n233-k16	19235.2	0.03%	19243.8	0.07%	19239.6	0.05%	19248.4	0.1%	19237.8	0.04%
X-n237-k14	27054	0.04%	27043.6	0.01%	27044.4	0.01%	27042.4	0%	27042.4	0%
X-n242-k48	82917.4	0.2%	82846.2	0.12%	82865.6	0.14%	82908.6	0.19%	82865.6	0.14%
X-n247-k50	37380.8	0.29%	37357.4	0.22%	37346.6	0.19%	37322.4	0.13%	37335.2	0.16%
X-n251-k28	38752.6	0.18%	38751.4	0.17%	38752.8	0.18%	38756.8	0.19%	38766.4	0.21%
X-n256-k16	18874.4	0.19%	18880	0.22%	18881.6	0.23%	18880	0.22%	18880	0.22%
X-n261-k13	26642.2	0.32%	26607.4	0.19%	26608.8	0.19%	26594.4	0.14%	26580.4	0.08%
X-n266-k58	75856	0.5%	75802.6	0.43%	75741.4	0.35%	75707.6	0.3%	75697.8	0.29%
X-n270-k35	35316.8	0.07%	35310.8	0.06%	35317.4	0.07%	35308.2	0.05%	35315.8	0.07%
X-n275-k28	21249	0.02%	21245	0%	21245	0%	21245	0%	21245	0%
X-n280-k17	33601.4	0.29%	33595.2	0.28%	33585.8	0.25%	33600.4	0.29%	33583.4	0.24%
X-n284-k15	20314	0.44%	20286.4	0.3%	20281.8	0.28%	20265.4	0.19%	20261.8	0.18%
X-n289-k60	95755.6	0.64%	95774.8	0.66%	95519.4	0.39%	95774	0.65%	95378.2	0.24%
X-n294-k50	47252.4	0.19%	47235.6	0.16%	47216	0.12%	47220.2	0.13%	47233.6	0.15%
X-n298-k31	34270.8	0.12%	34265.2	0.1%	34263	0.09%	34269.8	0.11%	34272.8	0.12%
X-n303-k21	21811.2	0.35%	21793.2	0.26%	21786.4	0.23%	21788.8	0.24%	21788.4	0.24%
X-n308-k13	25907.8	0.19%	25935.4	0.3%	25914.8	0.22%	25889.2	0.12%	25892.6	0.13%
X-n313-k71	94289.2	0.26%	94247.6	0.22%	94165.8	0.13%	94230.2	0.2%	94177.8	0.14%

¹¹Naudota originali realizacija

Uždavinys	1 gija ¹²		2 gijos		4 gijos		8 gijos		16 gijos	
	Avg	Spraga	Avg	Spraga	Avg	Spraga	Avg	Spraga	Avg	Spraga
X-n317-k53	78399	0.06%	78387.6	0.04%	78401.8	0.06%	78366.2	0.01%	78368.2	0.02%
X-n322-k28	29897.6	0.21%	29930.2	0.32%	29875.6	0.14%	29897.2	0.21%	29885.4	0.17%
X-n327-k20	27611	0.29%	27580.8	0.18%	27580.4	0.18%	27584	0.19%	27605.4	0.27%
X-n331-k15	31157.4	0.18%	31160.2	0.19%	31116	0.05%	31112.4	0.03%	31104.2	0.01%
X-n336-k84	140202.6	0.78%	139885	0.56%	139838	0.52%	139712.4	0.43%	139448.6	0.24%
X-n344-k43	42145.6	0.23%	42108.6	0.14%	42111.4	0.15%	42149.2	0.24%	42113.4	0.15%
X-n351-k40	25990	0.36%	25982	0.33%	25973.4	0.3%	25979.4	0.32%	25999.4	0.4%
X-n359-k29	51896.2	0.76%	52020.2	1%	51752.2	0.48%	51711.6	0.4%	51726.8	0.43%
X-n367-k17	22819.2	0.02%	22814	0%	22815.6	0.01%	22819.8	0.03%	22815.4	0.01%
X-n376-k94	147796.6	0.06%	147788.8	0.05%	147734	0.01%	147754.2	0.03%	147730.8	0.01%
X-n384-k52	66260	0.49%	66158.2	0.33%	66145.8	0.31%	66120.6	0.27%	66128.6	0.29%
X-n393-k38	38294.8	0.09%	38277.6	0.05%	38308.4	0.13%	38284.6	0.06%	38293.6	0.09%
X-n401-k29	66423.8	0.41%	66334.4	0.27%	66300.4	0.22%	66253.6	0.15%	66280.8	0.19%
X-n411-k19	19746.8	0.18%	19748.4	0.18%	19735.6	0.12%	19720	0.04%	19729.8	0.09%
X-n420-k130	107963.6	0.15%	107916.2	0.11%	107918.4	0.11%	107878.4	0.07%	107934.6	0.13%
X-n429-k61	65578.8	0.2%	65607.8	0.24%	65585.2	0.21%	65523.6	0.11%	65576.4	0.19%
X-n439-k37	36422.4	0.09%	36414.4	0.06%	36411.8	0.06%	36424.8	0.09%	36419	0.08%
X-n449-k29	55850.8	1.12%	55659	0.77%	55565	0.6%	55507	0.5%	55483.4	0.45%
X-n459-k26	24212.2	0.3%	24191.4	0.22%	24201.6	0.26%	24182.6	0.18%	24184.8	0.19%
X-n469-k138	223620	0.81%	223305.8	0.67%	223117.8	0.58%	222741.2	0.41%	222988.4	0.52%
X-n480-k70	89756.2	0.34%	89685.2	0.26%	89623.6	0.2%	89588.8	0.16%	89554.8	0.12%
X-n491-k59	66997.6	0.77%	66886.2	0.61%	66848.8	0.55%	66772.6	0.44%	66683.6	0.3%
X-n502-k39	69324	0.14%	69307.2	0.12%	69278.4	0.08%	69273.2	0.07%	69267.6	0.06%
X-n513-k21	24220.4	0.08%	24226.4	0.1%	24222	0.09%	24230.8	0.12%	24208	0.03%
X-n524-k153	154951.4	0.23%	154982.4	0.25%	154963.4	0.24%	155021.2	0.28%	154950.2	0.23%
X-n536-k96	95547.8	0.74%	95361.8	0.54%	95255.4	0.43%	95258	0.43%	95234.2	0.41%
X-n548-k50	87053	0.41%	86928	0.26%	86851.4	0.17%	86870.4	0.2%	86829.8	0.15%
X-n561-k42	42808	0.21%	42815	0.23%	42807.4	0.21%	42774.4	0.13%	42764.6	0.11%
X-n573-k30	51087.4	0.82%	51045.4	0.73%	50975	0.6%	50900.8	0.45%	50860.2	0.37%
X-n586-k159	191509.8	0.63%	191373.4	0.56%	191186.2	0.46%	190922	0.32%	190897	0.31%
X-n599-k92	109069.4	0.57%	109017.2	0.52%	109057.8	0.56%	108882.6	0.4%	108870.8	0.39%
X-n613-k62	59975	0.74%	59869.8	0.56%	59745.6	0.35%	59844.4	0.52%	59817.2	0.47%
X-n627-k43	62869.4	1.13%	62850.4	1.1%	62728.2	0.91%	62655.2	0.79%	62562.8	0.64%
X-n641-k35	64464.6	1.23%	64294	0.96%	64047.4	0.57%	64069.4	0.61%	63945.4	0.41%
X-n655-k131	106924.6	0.14%	106892.8	0.11%	106846.2	0.06%	106831	0.05%	106841.2	0.06%
X-n670-k130	147471.2	0.78%	147367.2	0.71%	147195.8	0.59%	147165.2	0.57%	147041.2	0.48%
X-n685-k75	68725	0.76%	68592.4	0.57%	68502.2	0.44%	68482.8	0.41%	68484.6	0.41%
X-n701-k44	83180.6	1.54%	83065.4	1.39%	82578.4	0.8%	82613.8	0.84%	82503	0.71%
X-n716-k35	43900.2	1.22%	43772.8	0.92%	43728.8	0.82%	43567.6	0.45%	43574	0.46%
X-n733-k159	136768	0.43%	136792	0.44%	136717.8	0.39%	136566.4	0.28%	136598.8	0.3%
X-n749-k98	78401.6	1.47%	78411.4	1.48%	78206.2	1.21%	78064.2	1.03%	77968.8	0.91%

¹²Naudota originali realizacija

Uždavinys	1 gija ¹³		2 gijos		4 gijos		8 gijos		16 gijos	
	Avg	Spraga	Avg	Spraga	Avg	Spraga	Avg	Spraga	Avg	Spraga
X-n766-k71	115315.2	0.79%	115179.4	0.67%	115114.4	0.61%	114935.8	0.45%	114904.2	0.43%
X-n783-k48	73721.4	1.84%	73577	1.65%	73425.4	1.44%	73074.6	0.95%	72998.6	0.85%
X-n801-k40	74229.8	1.25%	74182.6	1.19%	73988.2	0.92%	73847	0.73%	73724.2	0.56%
X-n819-k171	159540.4	0.9%	159153.2	0.65%	158976.2	0.54%	158891.2	0.49%	158885.2	0.48%
X-n837-k142	196146	1.24%	195816.2	1.07%	195501	0.91%	195255.2	0.78%	195175.4	0.74%
X-n856-k95	89094.2	0.15%	89112.2	0.17%	89093	0.14%	89044.6	0.09%	89101	0.15%
X-n876-k59	100509.8	1.22%	100395.4	1.1%	100196.4	0.9%	100084.4	0.79%	100048.8	0.76%
X-n895-k37	54604.8	1.38%	54511.8	1.21%	54272.4	0.77%	54208	0.65%	54249.4	0.72%
X-n916-k207	332510.6	1.01%	332303.2	0.95%	332145.8	0.9%	331893.8	0.82%	331591.6	0.73%
X-n936-k151	133835	0.84%	133767	0.79%	133855.8	0.86%	133585.6	0.66%	133661.4	0.71%
X-n957-k87	86039	0.67%	85958.4	0.58%	85765.2	0.35%	85721.8	0.3%	85681.8	0.25%
X-n979-k58	120554	1.33%	120308.2	1.12%	120170.2	1%	119805.4	0.7%	119821.6	0.71%
X-n1001-k43	73938.4	2.19%	73748.4	1.93%	73368.4	1.4%	73202	1.17%	73232.8	1.21%

¹³Naudota originali realizacija

Šaltiniai

- [AS20] M. F. Abdelatti ir M. S. Sodhi, „An improved GPU-accelerated heuristic technique applied to the capacitated vehicle routing problem“, *Proceedings of the 2020 Genetic and Evolutionary Computation Conference*, GECCO '20. ACM, birž. 2020, p. 663–671. doi: [10.1145/3377930.3390159](https://doi.org/10.1145/3377930.3390159).
- [Ada+24] T. Adamo, M. Gendreau, G. Ghiani, ir E. Guerriero, „A review of recent advances in time-dependent vehicle routing“, *European Journal of Operational Research*, t. 319, nr. 1, p. 1–15, lapkr. 2024, doi: [10.1016/j.ejor.2024.06.016](https://doi.org/10.1016/j.ejor.2024.06.016).
- [DR59] G. B. Dantzig ir J. H. Ramser, „The Truck Dispatching Problem“, *Management Science*, t. 6, nr. 1, p. 80–91, spal. 1959, doi: [10.1287/mnsc.6.1.80](https://doi.org/10.1287/mnsc.6.1.80).
- [DIM22] DIMACS, „The 12th DIMACS Implementation Challenge: Vehicle Routing Problems (VRP)“. 2022 m.
- [Jam+25] M. Jamshidi, M. Alirezanejad, H. Motameni, ir R. Enayatifar, „A Parallel Hybrid Genetic Search for Solving the Capacitated Vehicle Routing Problem“, *International Journal of Computational Intelligence Systems*, t. 18, nr. 1, lapkr. 2025, doi: [10.1007/s44196-025-01059-0](https://doi.org/10.1007/s44196-025-01059-0).
- [Jas+24] T. Jastrzab ir kt., „Standardized validation of vehicle routing algorithms“, *Applied Intelligence*, t. 54, nr. 2, p. 1335–1364, saus. 2024, doi: [10.1007/s10489-023-05212-0](https://doi.org/10.1007/s10489-023-05212-0).
- [Jia+22] S. Jiang, Z. He, W. Lin, F. Ma, ir Z. Lü, „FHCSolver: Fast hybrid CVRP solver“, *12th DIMACS implementation challenge: Vehicle routing problems*, 2022.
- [Koo+22] W. Kool ir kt., „Hybrid genetic search for the vehicle routing problem with time windows: A high-performance implementation“, *12th dimacs implementation challenge workshop*, 2022.
- [LHW25] Z. Lei, J.-K. Hao, ir Q. Wu, „Speeding up Local Optimization in Vehicle Routing with Tensor-based GPU Acceleration“. [Interaktyvus]. Adresas: <https://arxiv.org/abs/2506.17357>
- [Lat25] V. Latorre, „A hybrid genetic search based approach for the generalized vehicle routing problem“, *Soft Computing*, t. 29, nr. 3, p. 1553–1566, vas. 2025a, doi: [10.1007/s00500-025-10507-0](https://doi.org/10.1007/s00500-025-10507-0).
- [Lat25] V. Latorre, „An application of a two-level genetic search for the soft-clustered vehicle routing problem“, *Evolutionary Intelligence*, t. 18, nr. 4, liep. 2025b, doi: [10.1007/s12065-025-01063-5](https://doi.org/10.1007/s12065-025-01063-5).
- [Mun+23] R. P. Muniasamy, S. Singh, R. Nasre, ir N. Narayanaswamy, „Effective Parallelization of the Vehicle Routing Problem“, *Proceedings of the Genetic and Evolutionary Computation Conference*, GECCO '23. ACM, liep. 2023, p. 1036–1044. doi: [10.1145/3583131.3590458](https://doi.org/10.1145/3583131.3590458).

- [PF25] L. Perron ir V. Furnon, „OR-Tools“. [Interaktyvus]. Adresas: <https://developers.google.com/optimization/>
- [Pet+23] F. Petropoulos ir kt., „Operational Research: methods and applications“, *Journal of the Operational Research Society*, t. 75, nr. 3, p. 423–617, gruodž. 2023, doi: [10.1080/01605682.2023.2253852](https://doi.org/10.1080/01605682.2023.2253852).
- [Rez+24] B. Rezaei, F. Gadelha Guimaraes, R. Enayatifar, ir P. C. Haddow, „Exploring dynamic population Island genetic algorithm for solving the capacitated vehicle routing problem“, *Memetic Computing*, t. 16, nr. 2, p. 179–202, birž. 2024, doi: [10.1007/s12293-024-00412-8](https://doi.org/10.1007/s12293-024-00412-8).
- [SND23] T. Stadtler, S. Nita, ir J. Dünnweber, „A parallel hybrid genetic search for the capacitated vrp with pickup and delivery“, Ostbayerische Technische Hochschule Regensburg, 2023.
- [Uch+17] E. Uchoa, D. Pecin, A. Pessoa, M. Poggi, T. Vidal, ir A. Subramanian, „New benchmark instances for the Capacitated Vehicle Routing Problem“, *European Journal of Operational Research*, t. 257, nr. 3, p. 845–858, kovo 2017, doi: [10.1016/j.ejor.2016.08.012](https://doi.org/10.1016/j.ejor.2016.08.012).
- [Vid+12] T. Vidal, T. G. Crainic, M. Gendreau, N. Lahrichi, ir W. Rei, „A Hybrid Genetic Algorithm for Multidepot and Periodic Vehicle Routing Problems“, *Operations Research*, t. 60, nr. 3, p. 611–624, birž. 2012, doi: [10.1287/opre.1120.1048](https://doi.org/10.1287/opre.1120.1048).
- [Vid+14] T. Vidal, T. G. Crainic, M. Gendreau, ir C. Prins, „A unified solution framework for multi-attribute vehicle routing problems“, *European Journal of Operational Research*, t. 234, nr. 3, p. 658–673, geg. 2014, doi: [10.1016/j.ejor.2013.09.045](https://doi.org/10.1016/j.ejor.2013.09.045).
- [Vid+16] T. Vidal, N. Maculan, L. S. Ochi, ir P. H. Vaz Penna, „Large Neighborhoods with Implicit Customer Selection for Vehicle Routing Problems with Profits“, *Transportation Science*, t. 50, nr. 2, p. 720–734, geg. 2016, doi: [10.1287/trsc.2015.0584](https://doi.org/10.1287/trsc.2015.0584).
- [Vid+21] T. Vidal, R. Martinelli, T. A. Pham, ir M. H. Hà, „Arc Routing with Time-Dependent Travel Times and Paths“, *Transportation Science*, t. 55, nr. 3, p. 706–724, geg. 2021, doi: [10.1287/trsc.2020.1035](https://doi.org/10.1287/trsc.2020.1035).
- [Vid16] T. Vidal, „Technical note: Split algorithm in $O(n)$ for the capacitated vehicle routing problem“, *Computers & Operations Research*, t. 69, p. 40–47, 2016, doi: <https://doi.org/10.1016/j.cor.2015.11.012>.
- [Vid17] T. Vidal, „Node, Edge, Arc Routing and Turn Penalties: Multiple Problems—One Neighborhood Extension“, *Operations Research*, t. 65, nr. 4, p. 992–1010, rugpj. 2017, doi: [10.1287/opre.2017.1595](https://doi.org/10.1287/opre.2017.1595).
- [Vid22] T. Vidal, „Hybrid genetic search for the CVRP: Open-source implementation and SWAP* neighborhood“, *Computers & Operations Research*, t. 140, p. 105643, bal. 2022, doi: [10.1016/j.cor.2021.105643](https://doi.org/10.1016/j.cor.2021.105643).

- [YT21] P. Yelmewad ir B. Talawar, „Parallel Version of Local Search Heuristic Algorithm to Solve Capacitated Vehicle Routing Problem“, *Cluster Computing*, t. 24, nr. 4, p. 3671–3692, liep. 2021, doi: [10.1007/s10586-021-03354-9](https://doi.org/10.1007/s10586-021-03354-9).